

着陆腿设计代码审计报告

审计日期：2026-09-30。范围：当前工作区 `src`，重点为 `v2.5` 论文主线，以及仍保留的 `v3` 分支。结论：研究问题与先验分解方向值得保留，但当前代码尚不能直接视为冻结的论文真值链。发现的问题主要涉及统计定义、先验恢复、评价配置和物理量提取，并不指向“必须换一个更复杂的网络”。

本次只新增审计材料，没有修改 `src`、历史结果、登记簿或论文，没有同步远端、启动训练或中止任务。34 个 Python 文件通过语法解析；对核心依赖链进行了定向源码审查、原始生物数据重算、历史元数据检查及合成反例测试。没有逐行穷尽所有绘图和历史分支，也没有重跑 `Exudyn`、`R/PGLS` 或 `A100` 实验。当前选用的本地 Python 没有 `Exudyn`，因此涉及实际动力学影响幅度的结论均标为待验证。

证据包：`audit_probes.py`、`audit_probe_results.json`、`source_sha256.json`，均在本报告同目录。合成反例证明实现存在特定行为，不代表真实数据中误差的发生率或平均幅度。源码哈希记录工作区实际文件，不能仅用 `Git HEAD` 代替，因为当前目录处于整理后的未提交状态。

一 对 Claude 反馈的复核结论

同意把 `v0.5` 的问题定义作为主线：把鸟类形态统计转成质量条件设计先验，分离锚点、指数、宽度的贡献，再检验有限计算预算下的设计效益。这比预设鸟先验获胜更适合现有证据。

但登记为“接受”或“已修”不等于验收通过。本轮有两项直接改变前次反馈的状态。

第一， ± 0.016 不是 95% CI 半宽。用当前 `avonet_hwi.csv`、归档的同一物种筛选常量以及 `b_sensitivity.py` 的原 OLS 函数重算： $n=203$ ， $b=0.4067488503$ ， $SE=0.0155543734$ 。正态近似 95% 半宽为 0.0304866 ，采用 t 分布、201 自由度的半宽约 0.0306707 ，对应区间约 $[0.37608, 0.43742]$ 。原程序本来打印的就是 $b \pm SE$ 。登记簿和论文若改成 $b \pm 0.016$ (95% CI)，需要改回。这不否定斜率点估计，也不能直接据此判断工程性能优劣。

第二，`ER4b` 的 `S9` 修复只有主汇总表部分生效。零覆盖、分工况表、自举以及最优腿长汇总仍有问题，详见下文。不应把 `D-4` 的物理口径澄清等同于整条物理评价链已经验证。

其余反馈：

- 反推来源与 `common` 空间仍含其余九维生物信息，均与源码一致；旧考卷筛题仍在；`G-0` 区分合加速度和竖直量是正确修正，但本轮未独立重算其全部能量时程。`pgls_p4_guild.R` 默认两骨架各 25 棵，支持默认计划为 50 棵，不等于确认所有实际运行均成功得到 50 棵。日期修正未完全覆盖，`er3_search.py` 仍有 2026-10-01 注释，属于低优先级溯源问题。

二 论文主线优先修复的问题

1 生物统计误差条及目录整理后的断链

优先级 P1，原始数据已复核。位置：`src/stage6_surrogate/b_sensitivity.py`:25、49、74。

`ols` 返回标准误，打印也直接使用标准误。实际 $n=203$ 的复核结果见上文。与此同时，该脚本仍打开同目录 `allometry_flight.py`，但该文件已搬到 `legacy/src/stage6_surrogate`，当前直接运行会报 `FileNotFoundError`。因此“整理后的 `src` 能复现主斜率”目前不成立。

建议：把物种排除名单作为显式数据配置保存，带版本和来源；不要从另一个脚本的文本中用正则和 `eval` 抽取常量。输出结构化 `b`、`se`、`ci95`、`n`、样本名单与筛选哈希，避免再次把同一个 $\pm$ 解释为两种东西。修复路径不需要重跑工程仿真。

2 旧模型的先验不是按保存参数恢复

优先级 P1，真实元数据已复核。位置：`src/stage10_v2/e5_loop_v2.py:295`；`e17_emergent_b.py:104` 附近；`e20_gen_corridor.py:122`；`bioprior.py:110` 起。

若仅用 `arm`、`sigma`、`u_max` 创建 `BioPrior`，`a`、`b` 的来源、参考质量和其他范围会重新取当前代码或当前拟合文件。模型保存的 `prior.a` 和 `prior.b` 没有被用于严格恢复。同一归一化输出 `u` 因此可能变成另一条物理腿。

真实例子：`outputs/gl_geo_e5/model_meta.json` 保存参数对应 12 kg 中心腿长 110.4828 mm；仿照当前构造方式恢复得到 118.7083 mm，变化 +7.445%。这个数字体现“当前加载行为与历史保存行为不同”，不能仅归因于锚点，因为拟合源本身也会被重新读取。

建议：增加从完整快照恢复先验的接口，固定 `a`、`b`、`sigma`、`u_max`、全部维度范围、`clip`、单位与 `schema`。加载旧 `checkpoint` 时用快照解码；新锚点实验则产生新运行 ID。验收：若干质量和固定 `u` 的展开结果，应与保存时的 `X` 在舍入误差内一致。不能通过更改当前默认值悄悄升级历史模型。

3 E20 仍会丢掉第十个设计变量

优先级 P1，源码及维度反例已确认。位置：`src/stage10_v2/e20_gen_corridor.py:122`。

`run_arm` 构造先验时只传 `v21`，没有传 `v25`。十维生成器输出被九维先验展开，`q1_0` 被忽略；不加 `v21` 时甚至会退成七维。测试中长度为 10 的 `u` 输入得到长度为 9 的 `x`。E21 已加入按 `xd` 选择 `v25` 的逻辑，但 E20 没有同步。

E20/E21/E18b 还保留旧的 `_base` 评价入口，不统一经过 `evalcfg`；不能因为 ER3/E18c 已统一，就默认所有生成器验证图都与主工厂同物理。建议按 `checkpoint` 快照确定维度和物理配置并强校验，拒绝静默降维。历史图需要按生成配置判定是否可留；这里不直接宣布所有 E20 历史图作废。

4 ER4b 的截断修复尚未完成

优先级 P1，源码与合成测试已确认。位置：`src/stage10_v2/er4b_decompose.py:52`、74、148、169。

零覆盖时 `box_mean` 返回 `NaN`、0，`eval_box` 计算 $0 \times \text{NaN}$ 后上下界仍是 `NaN`；正确的无信息界应为 `[0, 1]`。随后 `nanmean` 可能将这些质量档从平均值分母中删掉。完全无信息不能转成“不计入这道题”。

分工况表直接取 `summarize` 的第 0 项，即截断条件均值，没有沿用 S9 界或逐格标记。自举同样对第 0 项求差；表头虽然写了有效性限制，但程序仍输出覆盖不足格子的数值区间，JSON 也没有逐格有效性标志。

覆盖率目前由 41 个等距点的命中比例近似。对 `log` 坐标盒 `[0.89, 1.09]` 和扫描域 `[0, 1]`，真实覆盖率为 0.55，代码为 0.560976，差 1.10 个百分点。这是离散积分误差，不应包装成严格连续先验界。

建议：在 `log L` 坐标上计算精确区间交长，并对分段线性插值做积分；零覆盖明确给 `[0, 1]`。两臂差值可先给保守识别界 `[lo_A-hi_B, hi_A-lo_B]`。所有表格和 JSON 使用同一统计对象；识别不确定性与抽样置信区间分开。修完可从已有扫描重做后处理，通常不需要重跑仿真。

5 ER4b 的最优腿长与自举单位需要重新限定

优先级 P1/P2，源码已确认，实际影响待量化。位置：er4b_decompose.py:169、183；el8c_abs_scan.py:77 附近。

最优峰值曲线把六工况的可行探针数先加总，再用总数是否达到 $6 \times \text{min_feas}$ 筛选；Amed/Amin 则 nanmean 掉无可行样本工况。于是“只在少数容易工况成功”的长度，也可能被选成“六工况平均峰值最优”。若想报告条件成功后的平均峰值，必须同时报告覆盖工况数；若想求跨六工况设计，应逐工况约束或另设明确失败代价。

E18c 每个工况、质量、长度格使用不同种子，但 ER4b 在所有格子共用同一组 probe 下标重采样。格子之间没有天然配对关系，这会引入任意的重采样相关性。同一格对不同先验积分应配对；不同独立格应独立抽样。此外，LHS 不是独立同分布随机点，当前 bootstrap 只能标为近似，最好用多次独立 LHS 扫描估计蒙特卡洛不确定性。

load_scan 也没有检查六个目标工况是否齐全、各 JSON 和 NPZ 的质量及长度网格是否一致；网格取最后一个文件的值。建议缺任一条件或网格不一致即拒绝生成正式汇总。

6 杆件质量与加速度传感器次序相反

优先级 P1，原函数合成测试已确认。位置：src/stage10_v2/physics_v2.py:193、283、381。

seg_mass 顺序为 tarso、tibio、femur；sAccR 顺序为 femur、tibio、tarso；_lateral 却按相同下标相乘。第一遍三个猜测质量相同时看不出来，结构定尺回代后各段质量不同就会出错。

合成例子中，正确反力比为 0.19750，原函数输出 0.08282。这个例子只是证明错误，不代表真实数据平均偏差。直接受影响的是反力、mu_demand、接触窗口，以及由该窗口定位的滑移统计；机身 a_res 本身不会因这段后处理自动改变。

建议传递具名的质量与传感器对；用直接接触反力再核对整机动量平衡。若未保存各杆加速度时程，历史 mu_demand 不能只凭现有汇总值精确修正。

7 腿行程包含离地间隙并混用了不同时刻的极值

优先级 P1，定义缺陷有合成反例，真实影响幅度未测。位置：physics_v2.py:177、321；physics_v3.py:267。

当前 $\text{stroke} = z_{\text{body}}(0) - \min(z_{\text{body}})$ ， $\text{sink} = \max(r - \min(z_{\text{foot}}), 0)$ ， $\text{leg_stroke} = \text{stroke} - \text{sink}$ 。初态足端有 gap0，且 $\text{gap0} = 0.3r$ ，bearing 半径上下限对应约 3.6–18 mm 间隙。一个完全不缩短、只是整条腿自由下降 10 mm 到触地的反例，会被这条公式记为 10 mm 腿行程。与 24 mm 行程约束相比，这个定义偏差不能直接忽略。

此外，机身最大下沉和地面最大侵入未必同时发生，“两个最大值相减”不等于“相对高度变化的最大值”。v3 还有俯仰，机身质心高度也不等于每个髌安装点高度。

建议分别定义机身绝对下沉、地面侵入、每条腿髌足相对压缩，按共同事件窗口从完整时程提取。v0 当前是离地初态速度，不应不加说明地称为触地瞬间速度。此项改变可行性筛选，修订前后需小样本重判，不能只改论文名词。

8 当前 slip 是端点净滑移，不是冲击期最大走开距离

优先级 P1/P2，原函数合成反例已确认。位置：physics_v2.py:409、419、587 附近。

函数取触地至全程机身最低点之间的末点净滑移，而不是窗口中最大绝对滑移。合成轨迹 $[0, 0.1, 0]$ m 在压缩期先滑出去再回来，返回 $\text{slip}=0$ ，尽管中途达到 100 mm。

另一个概念差异： $dx-r \cdot d\phi$ 描述相对地面的滚动校正后净滑移，没有减去机身位移；判据注释却称为“足端相对机体走开”。如果论文关心支撑稳定性，应直接定义髁足相对位置或支撑裕度；如果关心接触滑移，应使用接触点切向速度积分并区分净位移、最大偏离及累计滑移。三者不应互相代称。也应定位第一次冲击窗口，而非默认全程最低点属于首次冲击。

9 条件训练中的 Pareto 筛选跨了不同 Fr

优先级 P1，源码及最小反例已确认。位置：dataset_v2.py:194 附近；e5_loop_v2.py:174；dataset_v3.py:180 附近。

同一块中的每个设计具有自己的 Fr，但 Pareto 先在整个块内筛选，随后才把被选设计的 Fr 放入条件向量。纯竖直工况的低峰值设计会淘汰较高水平速度下的设计，尽管它并没有在同一个任务下击败后者。这不是条件可比的支配关系，也不是测试泄漏，而是训练目标样本的系统性偏选。

v2.5 还存在目标口径不统一：可行性用 a_{res} ，Pareto 与旧考卷 gap 用 peak_a ；ER3 用 a_{res} 。两者可以分别作为安全闸和优化目标，但必须明确目标不同，不能将其成绩直接拼成同一条方法排名。

建议对同一 Fr 评价多个设计后筛前沿；或用经过验证的条件代理模型构建条件一致的选择权重。主目标明确选竖直峰值还是合加速度。保留同一设计在不同 Fr 下的记录，缓存键需包含工况。生成反馈阶段也应保留生成时的 Fr；现代码生成后重新抽 Fr，得到的标签虽按实际 Fr 存储，不再是对原请求工况的直接反馈。

10 Windows 子进程会失去主进程的物理开关

优先级 P1，spawn 合成执行已确认；A100 历史影响待查。位置：e5_loop_v2.py:82、90、285、334；er3_search.py:31、83、90。

e5 的 V21、FOOT、V25、PLANAR 在 main 内改写，但 worker 从模块全局读取。Windows spawn 子进程重新导入模块后取到默认 `False/leg`。提取原 worker 函数并用假物理后端核验：主进程收到 `planar/bearing/unified=[1,1,1]`，spawn 子进程为 `[0,0,0]`。不是神经网络问题，是平台相关的配置传递问题。

ER3 的 COND 也在 main 改写，worker 重导入后可能回到默认 `turf1.2`。不能据此断言 Linux 上已有任务一定受影响：需记录 Python 版本和 multiprocessing 启动方式。建议像 `factory_v2` 那样在任务参数中显式传完整配置，或用 `initializer` 初始化 worker，并做父子进程配置哈希相等的断言。

11 实际搜索预算不等于标称预算

优先级 P2，真实结果及合成测试已确认。位置：er3_search.py:112、118。

本地六份 DE 结果均标 `budget=3000`，而 `n_eval=2880`；六份 random 为 3000。该差异来自整代取整，不能把这组数据称为完全相同的实际调用数。

更重要的是：所有不可行点都返回相同的 `1e9`，DE 的默认收敛判据会把整代相等认作收敛。6000 预算的十维、240 个体合成测试在 480 次评价后停止，并返回 `success=True`。这个 `success` 只表示优化器停止判据满足

，不等于找到可行设计。本地已下载的 ER3 样本没有出现这个 480 次情形，不能把反例写成它们的实际结果。

建议保存实际调用数、停止原因与首次可行时间；报 best-so-far 对实际调用数曲线。若协议要求固定预算，显式处理早停、重启或补足预算；对不可行点使用经过定义的违反程度，而非全部相同的惩罚值。早停本身不必禁止，但统计口径必须对齐。

12 断点续跑与配置戳仍允许混合版本

优先级 P1/P2，源码已确认。位置：factory_v2.py:252；e18c_abs_scan.py:163 附近；evalcfg.py:84、98。

factory 仅按 cid 判断已完成，并先覆盖 factory_meta.json；不校验旧行使用的先验、种子、材料和物理参数。更改参数后对同一个目录续跑，可能出现旧行与新行混合、目录却只保留新元数据。E18c/ER3 按结果文件是否存在跳过，也没有完整核验预算和配置；E18c 的 JSON 先于 NPZ 写出，异常中断后可能跳过一个没有探针数据的结果。

evalcfg 的集中化是进步，但 stamp 未覆盖求解器版本、代码哈希、步长、全部材料参数和先验展开参数；check_meta 对缺字段跳过，实际可能只核验了维度。建议固定 RunManifest、输入数据哈希和 schema，先验证后续跑；旧元数据缺关键字段时标为 unknown，而非认证为一致。结果文件对采用临时文件加原子替换，并检查完整性。

三 v3 分支的独立问题

以下问题属于 v3 轮足与俯仰分支，不应未经区分就归到 v2.5 论文结果上。源码定义已确认，但本轮未用 Exudyn 实跑量化。

13 髌力矩重建没有扣除机身俯仰

优先级 P1。位置：physics_v3.py:320。

v3 机身俯仰已放开，髌弹簧连接机身与股骨，但重建髌转角仍是股骨绝对转角相对初值。两者刚性同转时，相对髌角应为零，现公式却会产生髌弹性力矩。应使用股骨减机身的相对角与相对角速度，最好直接读取连接器力矩交叉核验。

同处用三个关节峰值的总和选择一条“worst”腿，不能保证它的每个关节都比另一腿更大。需要逐腿定尺后取相应构件包络，而不是选总和最大的整条腿代替各处最坏载荷。

14 停车判据将瞬时低速当成持续停住

优先级 P1/P2。位置：physics_v3.py:293。

代码只要求全程最小速度低于 0.10 m/s 且不在于最后三步，就认定 stopped=True；并把该瞬间速度写入 vx_end。存在反向、回弹或弹簧释能时，机身速度可过零后重新变大，因此注释中的“此后一直低速”没有实现。建议以持续时间窗口、剩余全过程速度上限和位移增量定义停车；vx_end 保留真正末态值，停车时刻速度另列。外推停车距离应单独标记，不和窗口内实测停车共用未经说明的可行率。

15 轮质量实现与账面质量不一致

优先级 P1/P2。位置：physics_v3.py:176。

轮刚体使用 InertiaCuboid，边长为 $[2r, 0.3r, 2r]$ ，但密度用圆柱体积 $\pi r^2 * 0.3r$ 相除。按长方体体积计算，实际惯性对象质量为 $4/\pi$ 倍 m_w ，约高 27.3%，而 M_{tot} 和质量预算使用 m_w 。应使用一致的惯性形状和质量定义，并在建模后读回各刚体质量求和验收。

此外，当前说明把两个模拟腿分别解释为左右一对，结构与轮组质量按四轮计，而动力学只创建两个轮刚体、未显式加入全部 hub/brake 质量。需要一张“模拟刚体代表哪些实体部件”的等效账本，不能只调整结果表的乘数。

四 需要物理验证而非直接宣布错误的建模风险

16 单腿与双腿等效及质量回代

v2.5 用一条三杆链承接 m ，结构定尺时将力和力矩除以 $NLEGS=2$ ，再把一根实体腿的段质量送回单链模型。若这条链是双腿聚合模型，聚合惯性、关节刚度和接触刚度应有一致的等效推导；若它是实体单腿，载荷分配又不能直接除二。现有代码没有完整给出这一对应关系。位置：physics_v2.py:193、442、496。

建议用对称双腿最小模型与等效模型做一组对照。npass=2 只保证做了两遍，不保证结构质量定点已收敛；应比较 2、3、4 遍的峰值、尺寸及质量。结构定尺后杆惯量横截面仍是固定 20 mm 方形，也应列为近似或更新。

17 能量恒等式不能替代完整物理验证

hf_exudyn._metrics 中 $F=m*(a_z+g)$ ， E_{abs} 来自该 F 对机身位移积分。与机身动能损失加重力功吻合，是重要的一致性检查，但没有独立核验杆件转动能、弹簧储能、地面接触能和数值耗散。physics_v2._lateral 的 e_{gain} 也只统计机身平动动能与重力势能，不是整机总能。

因此 E_{abs} 更适合解释为压缩段机身传递功，不能未经分解就称为不可逆耗散能。若定义 $F_{peak}=peak$ support force，则 $F_{peak}/(mg)=1+a_{z_peak}/g$ ；净加速度比并不直接等于效率的反比。校正 $G=0$ 的合量/分量之后，仍要统一事件窗口、速度时刻及能量对象。

建议先做自由落体、刚性平移、无阻尼保守系统、纯竖直对称、步长减半五类基准。此处没有实验证据证明目前全局能量一定不闭合；指出的是现有检查不足以证明它闭合。

18 生物统计与条件路径的附加限制

pgls_p4_guild.R:39 用 $\sqrt{SE_{base}^2 + SE_{interaction}^2}$ 合成非基准组斜率标准误，缺少 $2*Cov$ 项，注释“保守”不普遍成立。若协方差为正会低估。建议从协方差矩阵计算线性组合的标准误。M1 优于 M2 支持更简约的共同斜率模型，但不等于证明所有组斜率完全相同；需要区分模型偏好、差异检验和等效检验。

agroup_io.py:73 保留旧四闸，没有 a_{res} 、回弹和滑移完整口径；E22 的读盘路径会用它筛选 v2.5 数据。若这些图进入论文，应改成与主评价同 schema 的可行性函数，或明确标为旧闸下的诊断。selfcheck 只检查常量且导入失败返回 True，不能认证判据等价。

factory_v2 的 m_{iso} 只固定设计向量， $k=k_{ap}*m*g*L$ 仍随 m 改变，足半径、地面阻尼和结构也可能重算。因此它不是“同一套固定硬件只改变载荷”。kc walk 中 v_0 可能一起改变， Fr 又按 cid 重抽； m_{allo} 和 m_{iso} 使用不同 bundle 种子，也不是严格配对试验。可以保留为数据覆盖策略，但暂不据此宣称学到了单变

量物理导数或固定硬件迁移规律。

其他边界：关键指标为 NaN 时部分判据会跳过或回退；建议区分 legacy 字段缺失与当前求解无效。关节阻尼 $c=z*k$ 中 z 的量纲是时间，不是通常意义下的无量纲阻尼比。每轮反复查看同一 test 考卷虽不是直接把测试标签放进训练，也不能把它继续称为未触碰的最终测试集。

五 建议的最小修复顺序

第一步，冻结当前版本并保留所有原始探针、日志及配置，不要先把全量结果删掉重跑。将正在运行结果按已知配置归档；本轮没有依据要求无差别终止过夜任务。

第二步，先完成无需动力学重算的修复：SE/CI 标签、统计脚本断链、完整先验恢复、维度校验、ER4b 全路径输出和扫描完整性检查、实际预算对齐。以本报告合成反例作为回归测试输入，修复后测试应改为断言正确行为，而非继续断言旧缺陷。

第三步，做一组固定候选设计的物理口径回归：质量次序、行程、滑动窗口、单双腿等效、质量回代与步长收敛。至少覆盖轻/中/重质量、软/硬地、竖直/非零 Fr、可行边缘和失败样本。先观察可行性翻转率与方法排序稳定性，再决定哪些数据池必须重算。若只影响后处理且有时程，可重提指标；缺少时程才需要相应重仿真。

第四步，统一条件内选优与评价目标，再训练。工程先验仍按开发集构造、冻结后测试；共同评价任务不按各臂参考可行性筛掉难题。网络是否升级应放在这些步骤之后。

本轮最重要的建议：让“生物统计、先验展开、物理测量、条件内排序、最终测试”各自拥有可验收的接口。先把这条链做可信，现有简单 cVAE 就有机会支撑一篇清楚的文章；此时改 condition walk 或加大网络，会让错误更难归因，而不会自动增加论文可信度。